GUÍA PARA LA ELABORACIÓN DE LA SECCIÓN RESULTADOS (ATI3)

Revisión Sistemática de Literatura con estándar de publicación Q3–Q2

Formación para la Investigación

Docente: Mg. Jimmy Enrique Sánchez Portugal

1. Propósito de la sección Resultados

La sección Resultados **describe** lo que reporta la literatura del corpus. No interpreta, no opina y no propone; eso corresponde a la Discusión.

Cada afirmación debe estar respaldada por datos del corpus y por al menos una cita IEEE [n].

La redacción es formal, en tercera persona y en tiempo pasado o presente impersonal. Por ejemplo: "El 42 % de los estudios aplicó…" y nunca "Nosotros encontramos…".

Una revista Q3–Q2 no acepta una sección Resultados que solo cuenta artículos. Exige que el método de síntesis esté declarado, justificado y aplicado de forma reproducible, y que la confianza en cada hallazgo esté calificada. PRISMA 2020 [2] lo formaliza en los ítems 13a–13f (métodos de síntesis), 20a–20d (resultados de la síntesis) y 22 (certeza de la evidencia).

2. Prerrequisitos que deben venir cerrados desde ATI2

No se debe iniciar Resultados sin estos cinco elementos:

- **Corpus cerrado y suficiente:** 80 o más estudios si la tecnología tiene 10 años o más de literatura, y 35 o más si tiene menos. El número final debe ser idéntico en el PRISMA, la tabla de mapeo y la lista de referencias.
- **Corpus depurado:** sin ponencias de congreso, sin preprints de arXiv, sin tesis ni literatura gris, sin revisiones como estudios primarios y sin estudios ajenos al tema.
- **QA aplicado:** cada estudio con su puntaje en el instrumento de calidad.
- **Matriz de extracción completa:** un registro por estudio, trazable a su referencia [n].
- **Tabla de mapeo pregunta–estudio:** el 100 % del corpus vinculado a al menos una pregunta.

3. Estrategias, métodos y metodologías

3.1 Elección del método de síntesis según el tipo de pregunta

Síntesis temática. Thomas y Harden la describen [3] y Cruzes y Dybå la adaptan a la ingeniería de software [4]. Se usa cuando la pregunta busca identificar qué técnicas, factores, desafíos o beneficios reporta la literatura.

Procede en tres niveles: codificación línea a línea de los hallazgos extraídos, agrupación en temas descriptivos y, ya en la Discusión, temas analíticos. En Resultados solo se reportan los dos primeros niveles.

Síntesis narrativa estructurada. Sigue la guía de Popay et al. [5]. Se usa cuando los estudios son heterogéneos en diseño y métricas y no pueden combinarse numéricamente.

Organiza los estudios por agrupaciones explícitas (tipo de técnica, contexto, diseño), presenta los resultados en tablas comparativas y explora las relaciones entre las características de los estudios y sus hallazgos.

Síntesis sin metaanálisis (SWiM). Es la guía de reporte de Campbell et al. [6]. Se usa cuando la pregunta busca saber si una intervención mejora un resultado (precisión, tiempo o costo) pero las métricas no son combinables.

Se aplica el conteo de votos por dirección del efecto: cuántos estudios reportan mejora, ninguna diferencia o empeoramiento frente al comparador. Prohíbe contar solo los resultados "significativos" y exige declarar cómo se agruparon los estudios.

Metaanálisis. Solo procede si al menos 3 estudios comparten diseño, comparador y una métrica con medida de dispersión. Es poco frecuente en ingeniería de software; si no es viable, debe declararse explícitamente por qué (heterogeneidad de métricas o datasets).

Mapeo sistemático con gráficos de burbujas. Lo proponen Petersen, Vakkalanka y Kuzniarz [7]. Se usa para las preguntas bibliométricas y de cobertura.

Cruza dos dimensiones, por ejemplo técnica frente a contexto o tipo de contribución frente a tipo de investigación. El tamaño de cada burbuja es el número de estudios, de modo que se visualizan de inmediato las concentraciones y los vacíos de evidencia.

Análisis bibliométrico de redes. Usa Bibliometrix y Biblioshiny [8] o VOSviewer [9]. Una revista Q2 suele esperar al menos un mapa de coocurrencia de palabras clave y, si el corpus lo permite, una red de coautoría o de países.

Estos análisis se ejecutan sobre la exportación original de Scopus o WoS restringida al corpus final.

3.2 Estrategias de rigor que distinguen un artículo Q3–Q2

Extracción por duplicado. Ambos integrantes extraen de forma independiente una muestra de al menos el 20 % del corpus, se calcula el Kappa de Cohen sobre los campos categóricos (ver 3.4) y se resuelven los desacuerdos por consenso. Se reporta el valor obtenido.

Síntesis ponderada por calidad. Los resultados del QA se integran en la síntesis, no se reportan aparte. Se indica cuántos estudios de calidad alta respaldan cada categoría.

Análisis de sensibilidad. Se repite el conteo de cada pregunta excluyendo los estudios de calidad baja. Si la tendencia se mantiene, el hallazgo es robusto; si cambia, se reporta.

Certeza de la evidencia por hallazgo. Para los hallazgos cualitativos se usa GRADE-CERQual [10], que califica la confianza como alta, moderada, baja o muy baja según cuatro componentes: limitaciones metodológicas, coherencia, adecuación de los datos y relevancia. Para los hallazgos sobre efectos se usa GRADE de forma adaptada.

Disponibilidad de datos. La matriz de extracción, la exportación de la búsqueda y el código de los gráficos se publican en OSF o Zenodo y se cita su DOI. Muchas revistas Q2 lo exigen como declaración de disponibilidad de datos.

3.3 Herramientas recomendadas

- **Extracción y conteos:** Excel con tablas dinámicas, o Python con pandas.
- **Codificación cualitativa:** Taguette (gratuita), ATLAS.ti o NVivo.
- **Gráficos de barras, líneas, burbujas y mapas de calor:** Python con matplotlib o seaborn.
- **Redes bibliométricas:** Biblioshiny o VOSviewer.
- **Kappa de Cohen:** Python con sklearn.metrics.cohen_kappa_score, o una calculadora estadística.

Nota: Petersen et al. (2008) y Cruzes y Dybå (2011, ESEM) son ponencias de congreso. Por la regla del curso se citan sus versiones en revista [4], [7].

3.4 El Kappa de Cohen: qué es, dónde se aplica y cómo se reporta

Qué mide

El Kappa de Cohen (κ) [14] mide el grado de acuerdo entre dos evaluadores que clasifican los mismos elementos de forma independiente, descontando el acuerdo que ocurriría por azar. Por eso es más exigente que el simple porcentaje de coincidencia.

$$\kappa = (Po - Pe) / (1 - Pe)$$

- **Po** es el acuerdo observado: la proporción de elementos en que ambos evaluadores coinciden.
- **Pe** es el acuerdo esperado por azar, calculado con las proporciones con que cada evaluador usó cada categoría.

Interpretación. Según Landis y Koch [11], el acuerdo es moderado entre 0,41 y 0,60, sustancial entre 0,61 y 0,80, y casi perfecto por encima de 0,80. McHugh [12] advierte que en investigación conviene exigir valores de 0,80 o más.

Regla de la guía:

- **κ ≥ 0,80:** acuerdo aceptable.
- **κ entre 0,61 y 0,79:** se reconcilian los desacuerdos, se afinan las definiciones y se repite con una muestra nueva.
- **κ ≤ 0,60:** las categorías o criterios están mal definidos y deben reformularse antes de continuar.

Condiciones de uso:

- Se aplica a datos categóricos: incluir o excluir, categoría temática, nivel de calidad, dirección del efecto. No se aplica a valores numéricos continuos; para ellos basta la verificación cruzada de que el dato coincide con la página del artículo.
- Es para dos evaluadores. Si participan tres o más, se usa el Kappa de Fleiss.
- En los trabajos individuales, el segundo evaluador debe ser externo, por ejemplo un compañero del curso, y se declara su participación.

- Paradoja de la prevalencia: cuando una categoría domina, κ puede salir bajo aunque el acuerdo real sea alto. Por eso siempre se reporta κ junto al porcentaje de acuerdo y al tamaño de la muestra.

Dónde se aplica en la RSL

- **Cribado por título y resumen (Metodología, ATI2):** ambos integrantes deciden "incluir o excluir" sobre una muestra aleatoria de los registros.
- **Elegibilidad a texto completo (Metodología, ATI2):** ambos deciden "incluir o excluir con código" sobre los textos completos evaluados.
- **Extracción de campos categóricos (Resultados, Paso 3):** diseño metodológico, contexto o tipo de técnica, sobre la misma muestra de estudios.
- **Asignación de categorías temáticas (Resultados, Paso 7):** es la aplicación más importante en Resultados, porque demuestra que las categorías son reproducibles y no una interpretación individual.
- **Evaluación de calidad (Resultados, Paso 6):** como el nivel de calidad es ordinal, se usa el Kappa ponderado [13], que penaliza menos un desacuerdo entre "alta" y "media" que uno entre "alta" y "baja".
- **Dirección del efecto en preguntas SWiM (Resultados, Paso 7):** ambos clasifican cada estudio como "mejora", "sin diferencia" o "empeora" frente al comparador.

Ejemplo 1 — Cribado (dos categorías)

Dos integrantes cribaron de forma independiente una muestra aleatoria de 40 registros: ambos marcaron "incluir" en 12 casos y "excluir" en 22. En 3 casos el evaluador 1 incluyó y el 2 excluyó, y en otros 3 ocurrió lo contrario.

- **Acuerdo observado:** Po = (12 + 22) / 40 = 0,85.
- **Proporciones de cada evaluador:** cada uno incluyó 15 de 40 registros (0,375) y excluyó 25 de 40 (0,625).
- **Acuerdo por azar:** Pe = (0,375 × 0,375) + (0,625 × 0,625) = 0,5313.
- **Kappa:** κ = (0,85 − 0,5313) / (1 − 0,5313) = 0,68.

Lectura: el acuerdo es sustancial, pero no alcanza 0,80, aunque los evaluadores coincidieron en el 85 % de los casos. Corresponde revisar los 6 desacuerdos, precisar el criterio que los causó y repetir con 40 registros nuevos.

Ejemplo 2 — Categorías temáticas de una pregunta (cuatro categorías)

En PI1 hay cuatro categorías: A (aprendizaje profundo), B (modelos de lenguaje), C (aprendizaje automático clásico) y D (híbridos). Dos integrantes clasificaron de forma independiente 20 estudios.

- **Coincidencias:** 6 en A, 5 en B, 3 en C y 2 en D, es decir, 16 de 20.
- **Desacuerdos:** un estudio A del evaluador 1 fue C para el evaluador 2; un estudio B fue C; un estudio C fue D; y un estudio D fue A.
- **Totales:** el evaluador 1 asignó A 7, B 6, C 4 y D 3; el evaluador 2, A 7, B 5, C 5 y D 3.
- **Cálculo:** Po = 16 / 20 = 0,80; Pe = [(7 × 7) + (6 × 5) + (4 × 5) + (3 × 3)] / 400 = 0,27; κ = (0,80 − 0,27) / (1 − 0,27) = 0,73.

Lectura: el acuerdo es sustancial. Tres de los cuatro desacuerdos involucran a la categoría C, lo que indica que su definición es ambigua frente a A y B. Se redefine C y se registra el cambio en la bitácora de codificación.

Ejemplo 3 — Calidad con Kappa ponderado

Dos integrantes clasificaron la calidad de 25 estudios como alta, media o baja. Si la mayoría de los desacuerdos fueron entre "alta" y "media", el Kappa ponderado será mayor que el simple, porque esos desacuerdos son de un solo nivel.

Si hubo desacuerdos entre "alta" y "baja", el Kappa ponderado los castiga más. Se reporta el Kappa ponderado cuadrático, que es el más usado para escalas ordinales.

Ejemplo 4 — Dirección del efecto (SWiM)

Para PI3 ("¿mejora la exactitud frente al comparador?"), dos integrantes clasificaron 18 estudios como "mejora", "sin diferencia" o "empeora", con κ = 0,84. El acuerdo es casi perfecto, por lo que el conteo de votos es confiable.

Cálculo en Python

```
from sklearn.metrics import cohen_kappa_score
ev1 = ["A"]*7 + ["B"]*6 + ["C"]*4 + ["D"]*3
ev2 = ["A"]*6 + ["C"] + ["B"]*5 + ["C"] + ["C"]*3 + ["D"] + ["D"]*2 + ["A"]
print(round(cohen_kappa_score(ev1, ev2), 2))   # 0.73
# Calidad ordinal: cohen_kappa_score(c1, c2, weights="quadratic")
```

Las dos listas deben tener el mismo orden de estudios: cada posición corresponde al mismo artículo.

Cómo se reporta en el artículo

En la Metodología: *"El cribado por título y resumen se realizó de forma independiente por ambos autores sobre una muestra aleatoria de 40 registros (κ = 0,68; acuerdo 85 %). Tras reconciliar los desacuerdos y precisar el criterio EX3, una segunda muestra de 40 registros alcanzó κ = 0,86 (acuerdo 95 %)."*

En Resultados: *"La asignación de categorías de PI1 se verificó por duplicado en 20 estudios (23,8 % del corpus), con κ = 0,73 (acuerdo 80 %). Los desacuerdos se concentraron en la categoría C, cuya definición se precisó antes de clasificar el resto del corpus."*

Evidencia que se adjunta: la hoja con las decisiones de ambos evaluadores, una columna por cada uno, y el registro de cómo se resolvió cada desacuerdo.

4. Pasos para elaborar la sección Resultados

Paso 1 — Congelar el corpus

Para qué sirve. "Congelar" significa fijar definitivamente qué artículos forman parte de tu revisión. Si el corpus cambia mientras redactas, todos los conteos, porcentajes y tablas quedan desactualizados y tendrás que rehacerlos.

Qué necesitas. Tu diagrama PRISMA final, tu tabla de mapeo de ATI2 y tu lista de referencias.

Cómo hacerlo:

1. Cuenta los estudios de la fase "Incluidos" del PRISMA. Anota ese número: es tu **n final**.

2. Cuenta las filas de tu tabla de mapeo. Debe dar exactamente el mismo n.
3. Revisa tu lista de referencias y marca cuáles son estudios del corpus y cuáles son referencias de contexto (introducción, guías metodológicas). El número de estudios del corpus debe ser el mismo n.
4. Si los tres números no coinciden, **detente**: busca qué estudio falta o sobra y corrige antes de seguir.
5. Crea en Excel una hoja llamada "Corpus" con cuatro columnas: ID (S01, S02, S03…), número IEEE [n], primer autor y año, y título.
6. Revisa por última vez que ningún estudio sea una ponencia de congreso, un preprint de arXiv, una tesis o una revisión. Si encuentras alguno, exclúyelo ahora y actualiza el PRISMA.
7. A partir de este momento, el ID y el número [n] de cada estudio **no cambian**.

Ejemplo. El PRISMA dice "Incluidos: 84", la tabla de mapeo tiene 84 filas y la lista tiene 84 estudios del corpus más 12 referencias de contexto. El corpus está congelado. Si la tabla de mapeo tuviera 82 filas, faltan 2 estudios por mapear.

Producto. La hoja "Corpus" con n filas, cada una con su ID y su [n].

Errores comunes. Seguir agregando artículos "porque encontré uno bueno" mientras se redacta; tener un n distinto en el resumen, el PRISMA y el texto.

Paso 2 — Declarar el método de síntesis de cada pregunta

Para qué sirve. No todas las preguntas se responden igual. Una pregunta que busca qué técnicas existen se responde de forma distinta a una que busca si una técnica mejora un resultado. Decidir el método antes de analizar evita que acomodes los resultados a tu conveniencia.

Qué necesitas. La lista de tus preguntas de investigación (pregunta principal, PI1, PI2… y preguntas bibliométricas).

Cómo hacerlo:

1. Escribe cada pregunta en una lista.
2. Identifica la palabra clave de cada una y clasifícala según su tipo:
   - "¿Qué…?", "¿Cuáles…?": pregunta de **identificación**.
   - "¿Mejora…?", "¿En qué medida…?", "¿Comparado con…?": pregunta de **efecto**.
   - "¿Cómo…?", "¿Bajo qué condiciones…?": pregunta de **mecanismo**.
   - "¿Qué limitaciones…?", "¿Qué barreras…?": pregunta de **desafíos**.
   - "¿Cuántos…?", "¿Dónde…?", "¿Cuándo…?": pregunta **bibliométrica**.
3. Asigna el método según el tipo:
   - **Identificación y desafíos:** síntesis temática.
   - **Efecto:** SWiM, con conteo de votos por dirección del efecto.
   - **Mecanismo:** síntesis narrativa estructurada.
   - **Bibliométrica:** mapeo sistemático.
4. Escribe una línea de justificación por pregunta.
5. Copia esa lista en la Metodología, en un apartado llamado "Métodos de síntesis".

Ejemplo. *"PI1 (¿Qué técnicas de IA se aplican?): pregunta de identificación; se aplicó síntesis temática porque se busca construir una tipología de técnicas." "PI3 (¿Mejoran la precisión frente a métodos tradicionales?): pregunta de efecto; se aplicó SWiM porque las métricas de los estudios no son combinables numéricamente."*

Producto. Una lista de preguntas, cada una con su tipo, su método y su justificación.

Errores comunes. Usar el mismo método para todas las preguntas; decidir el método después de ver los datos.

Paso 3 — Construir la matriz de extracción y extraer por duplicado

Para qué sirve. La matriz es tu base de datos. Todo lo que escribas en Resultados debe salir de ella. Si un dato no está en la matriz, no puede aparecer en el artículo.

Qué necesitas. Los PDF completos de todos los estudios del corpus, la hoja "Corpus" y Excel.

Cómo hacerlo:

1. Crea una hoja "Matriz general" con una fila por estudio y estas columnas: ID, [n], año, revista, país, diseño metodológico, población o contexto, técnica o intervención, comparador, métrica principal, valor obtenido, valor del comparador, dirección del efecto, ¿reporta dispersión? (sí/no) y puntaje QA.
2. Define por escrito la regla del país antes de empezar. Por ejemplo: "País donde se realizó el estudio; si no se indica, país de afiliación del primer autor". Aplícala a todos los estudios por igual.
3. Crea una hoja por cada pregunta (PI1, PI2…) con estas columnas: ID, [n], fragmento literal (40 palabras como máximo), página, dato cuantitativo, código, categoría, dirección del efecto y calidad.
4. Crea una hoja "Bitácora" con estas columnas: fecha, código, definición, categoría, quién lo creó y observaciones.
5. Lee cada artículo y llena su fila. Copia el fragmento exacto que responde cada pregunta y anota la página. Si el artículo no reporta un dato, escribe "No reporta"; **nunca lo inventes ni lo supongas**.
6. Elige al azar el 20 % de los estudios (por ejemplo, con =ALEATORIO() en Excel) y pide a tu compañero que los extraiga **sin mirar lo que tú hiciste**.
7. Compara ambas extracciones en los campos categóricos (diseño, contexto, técnica), calcula el Kappa de Cohen y anota el resultado.
8. Revisen juntos cada diferencia, decidan la respuesta correcta volviendo al artículo y registren la decisión en la bitácora.

Ejemplo. Fila de PI1: *"S07 | [24] | 'The proposed BERT-based classifier was fine-tuned on 12,000 tickets…' | p. 5, Sec. III-B | Exactitud 0,92 frente a 0,81 de SVM | Código: transformer-ajustado | Categoría: Modelos de lenguaje | Mejora | Alta"*.

Producto. La matriz general completa, una hoja por pregunta, la bitácora y el Kappa de extracción calculado.

Errores comunes. Llenar la matriz leyendo solo el resumen; parafrasear en lugar de copiar el fragmento literal; no anotar la página; hacer la extracción doble mirando la del compañero.

Paso 4 — Realizar el análisis bibliométrico y de redes

Para qué sirve. Muestra quién, cuándo, dónde y en qué revistas se ha investigado el tema. Le permite al lector entender el panorama antes de leer los hallazgos.

Qué necesitas. La matriz general y la exportación de Scopus o WoS en CSV o BibTeX, filtrada solo a los estudios del corpus.

Cómo hacerlo:

1. **Distribución por año.** Con una tabla dinámica, cuenta los estudios por año. Incluye todos los años de tu ventana temporal, aunque alguno tenga cero. Haz un gráfico de barras o de líneas.
2. **Revistas.** Cuenta los estudios por revista y ordena de mayor a menor. Presenta el top 5–10 en una tabla con el nombre de la revista, el n y el porcentaje.
3. **Autores.** Cuenta cuántos estudios tiene cada autor. Si nadie tiene más de uno, escríbelo así, porque también es un hallazgo: indica que el campo está disperso.
4. **Países.** Aplica la regla definida en el Paso 3 y presenta los países en una tabla y un mapa o gráfico de barras.
5. **Mapa de palabras clave.** Instala VOSviewer (gratuito), carga la exportación del corpus, elige "Co-occurrence → Author keywords", define un umbral mínimo (por ejemplo, 3 apariciones) y exporta la imagen en alta resolución. Anota el umbral usado.
6. Redacta un párrafo corto por cada análisis, describiendo solo lo que muestran los datos.

Ejemplo. *"Los 84 estudios se publicaron entre 2016 y 2026, con un crecimiento sostenido desde 2021: el 71,4 % (60 de 84) corresponde al periodo 2022–2026 (Fig. 2). Expert Systems with Applications concentró el mayor número de estudios (9; 10,7 %) (Tabla III)."*

Producto. Tablas y figuras por año, revista, autor y país, el mapa de coocurrencia y un párrafo descriptivo por análisis.

Errores comunes. Omitir los años sin publicaciones; hacer el mapa con toda la búsqueda y no solo con el corpus; no declarar el umbral.

Paso 5 — Clasificar los diseños metodológicos

Para qué sirve. No es lo mismo un experimento controlado que una prueba de concepto. Saber qué tipo de estudios predomina indica qué tan sólida es la evidencia.

Qué necesitas. La columna "diseño metodológico" de la matriz.

Cómo hacerlo:

1. Usa estas categorías, definidas antes de clasificar:
   - **Experimental:** compara con un grupo o modelo de control bajo condiciones controladas.
   - **Cuasi-experimental:** compara, pero sin control total de las condiciones.
   - **Caso de estudio:** aplica la solución en una organización real.
   - **Encuesta o entrevista:** recoge percepciones de usuarios o expertos.
   - **Desarrollo de artefacto o prueba de concepto:** construye un sistema y lo prueba de forma limitada.
   - **Simulación:** usa datos o entornos simulados.
   - **Mixto:** combina dos o más diseños.

2. Lee la sección de metodología de cada estudio y asígnale una categoría.
3. Verifica la clasificación con tu compañero sobre la muestra del 20 % y calcula el Kappa.
4. Cuenta las frecuencias y los porcentajes.
5. Describe qué diseño predomina y qué implica, sin opinar. Por ejemplo: "solo el 14 % incluyó un grupo de comparación".

Producto. Una tabla y un gráfico de diseños metodológicos, con un párrafo descriptivo.

Errores comunes. Llamar "experimento" a cualquier prueba; inventar categorías nuevas para cada estudio.

Paso 6 — Reportar la calidad e integrarla al análisis

Para qué sirve. No todos los estudios valen lo mismo. Una revista Q3–Q2 espera que indiques cuántos estudios sólidos respaldan cada hallazgo.

Qué necesitas. El instrumento QA de ATI2 y el puntaje de cada estudio.

Cómo hacerlo:

1. Verifica que cada estudio tiene su puntaje QA. Si falta alguno, evalúalo ahora con el texto completo.
2. Asigna un nivel a cada estudio según el umbral declarado. Por ejemplo, con 5 preguntas: 4–5 puntos es calidad alta, 2,5–3,5 es media y menos de 2,5 es baja.
3. Pide a tu compañero que puntúe la misma muestra del 20 % y calcula el **Kappa ponderado**, porque los niveles tienen orden.
4. Cuenta cuántos estudios hay en cada nivel y cuál fue la pregunta QA que más se incumplió.
5. En la matriz, agrega una columna "Incluir en sensibilidad" y marca "No" en los estudios de calidad baja.

Ejemplo. *"El 52,4 % de los estudios (44 de 84) obtuvo calidad alta, el 35,7 % (30) media y el 11,9 % (10) baja. El criterio más incumplido fue QA3, comparación con línea base, ausente en 38 estudios (45,2 %) (Tabla IV)."*

Producto. Una tabla de distribución de calidad, el Kappa ponderado y la columna de sensibilidad marcada.

Errores comunes. Puntuar la calidad leyendo solo el resumen; poner a todos "calidad alta".

Paso 7 — Aplicar el método de síntesis a cada pregunta

Para qué sirve. Es el corazón de Resultados. Aquí transformas los fragmentos extraídos en categorías y conteos que responden tus preguntas.

Qué necesitas. La hoja de cada pregunta, con sus fragmentos literales.

Cómo hacerlo (síntesis temática, para preguntas de identificación y desafíos):

1. **Codificación abierta.** Lee cada fragmento y asígnale un código corto (2–4 palabras) que resuma la idea. Por ejemplo: "BERT ajustado", "random forest", "reglas + LLM".
2. **Registro.** Anota cada código nuevo en la bitácora, con su definición.

3. **Agrupación.** Cuando tengas todos los códigos, agrupa los parecidos. Por ejemplo, "BERT ajustado", "GPT con prompts" y "LLaMA" forman la categoría "Modelos de lenguaje".
4. **Definición.** Escribe una oración que defina cada categoría y que permita a otra persona clasificar sin dudar.
5. **Verificación.** Pide a tu compañero que, con solo tus definiciones, clasifique la muestra del 20 %. Calcula el Kappa. Si es menor que 0,80, mejora las definiciones y repite.
6. **Conteo.** Cuenta cuántos estudios hay en cada categoría y calcula su porcentaje sobre los estudios de esa pregunta.

Cómo hacerlo (SWiM, para preguntas de efecto):

1. Agrupa los estudios por comparador (por ejemplo, "frente a método manual" o "frente a SVM") y por métrica (exactitud, tiempo, F1).
2. En cada estudio, marca la dirección del efecto: **mejora** si la técnica supera al comparador, **sin diferencia** si el estudio reporta resultados equivalentes y **empeora** si queda por debajo.
3. Verifica la dirección del efecto con tu compañero y calcula el Kappa.
4. Cuenta los votos: cuántos estudios reportan mejora, sin diferencia y empeora.
5. Reporta el rango de la métrica, del valor mínimo al máximo. **No promedies** valores de estudios distintos.
6. Elabora un gráfico de barras divergentes: mejora a la derecha, empeora a la izquierda.

Cómo hacerlo (mapeo, para preguntas bibliométricas o de cobertura):

1. Elige dos dimensiones para cruzar. Por ejemplo, técnica frente a sector de aplicación.
2. Cuenta cuántos estudios hay en cada combinación.
3. Elabora un gráfico de burbujas: el tamaño de cada burbuja es el número de estudios.
4. Identifica las combinaciones vacías, que son los vacíos de investigación.

Producto. Por cada pregunta: categorías con su definición, conteos, Kappa y, si aplica, el conteo de votos o el gráfico de burbujas.

Errores comunes. Crear las categorías antes de leer los fragmentos; dejar una categoría con un solo estudio; promediar exactitudes de datasets distintos.

Paso 8 — Realizar el análisis de sensibilidad

Para qué sirve. Comprueba si tus hallazgos se sostienen cuando quitas los estudios de calidad baja. Si se sostienen, son robustos.

Qué necesitas. Los conteos del Paso 7 y la columna "Incluir en sensibilidad".

Cómo hacerlo:

1. Filtra la hoja de cada pregunta dejando solo los estudios de calidad media y alta.
2. Repite los conteos y los porcentajes de cada categoría.
3. Compara ambos resultados: ¿cambió la categoría más frecuente? ¿Cambió la dirección del efecto?
4. Escribe una oración por pregunta con el resultado.

Ejemplo. *"Al excluir los 10 estudios de calidad baja, los enfoques híbridos se mantuvieron como la categoría más frecuente (34,6 %; 27 de 78)."*

Producto. Una tabla de sensibilidad (conteos con y sin calidad baja) y una oración por pregunta.

Errores comunes. Omitir este paso; no reportarlo cuando el resultado cambia.

Paso 9 — Calificar la certeza de cada hallazgo principal

Para qué sirve. Le dice al lector cuánta confianza puede tener en cada hallazgo. Es lo que más distingue a un artículo Q2.

Qué necesitas. Los hallazgos principales de cada pregunta (normalmente, uno por categoría importante).

Cómo hacerlo:

1. Escribe cada hallazgo en una oración. Por ejemplo: "Los enfoques híbridos son la técnica más aplicada".
2. Evalúa cuatro aspectos (GRADE-CERQual simplificado) y marca en cada uno si hay preocupación nula, menor, moderada o seria:
   - **Limitaciones metodológicas:** ¿los estudios que lo respaldan son de calidad baja?
   - **Coherencia:** ¿los estudios dicen lo mismo o se contradicen?
   - **Adecuación:** ¿hay suficientes estudios y datos para sostenerlo?
   - **Relevancia:** ¿los estudios corresponden realmente a tu población y contexto?
3. Asigna la confianza: **alta** si no hay preocupaciones relevantes, **moderada** si hay una preocupación, **baja** si hay varias y **muy baja** si son serias.
4. Escribe una línea de justificación.

Ejemplo. *"Hallazgo: los enfoques híbridos mejoran la exactitud frente a modelos no híbridos. Confianza: moderada. Justificación: 10 de 14 estudios reportan mejora (coherencia aceptable), pero 4 no reportan diferencias y 3 son de calidad media."*

Producto. Una tabla de resumen de hallazgos con el hallazgo, los estudios que lo respaldan, la confianza y la justificación.

Errores comunes. Poner confianza "alta" a todo; justificar con opiniones en lugar de los cuatro aspectos.

Paso 10 — Elaborar una tabla y una figura por pregunta

Para qué sirve. Las tablas y figuras permiten ver los datos de un vistazo y son obligatorias por cada pregunta.

Qué necesitas. Los conteos de los Pasos 7 y 8.

Cómo hacerlo:

1. **Tabla.** Crea una tabla por pregunta con las columnas: categoría, estudios [n], n y %. Ordena de mayor a menor.
2. **Tipo de figura** según el dato:
   - categorías: barras horizontales ordenadas;

- evolución por año: líneas;
- cruce de dos dimensiones: burbujas o mapa de calor;
- dirección del efecto: barras divergentes.

3. Construye la figura con Excel o Python **a partir de la tabla**, nunca con datos escritos a mano.
4. Ponle nombre y unidad a cada eje, usa letra legible (mínimo 8 puntos al tamaño final) y exporta en 300 ppp.
5. Usa el formato IEEE: "TABLA V" con el título encima y "Fig. 3." con el pie debajo.
6. Agrega al pie la fuente: "Elaboración propia a partir de [12]–[95]".
7. Cita la tabla y la figura en el texto **antes** de que aparezcan.

Producto. Al menos una tabla y una figura por pregunta, numeradas y citadas.

Errores comunes. Figuras con datos distintos a la tabla; gráficos circulares con muchas categorías; figuras generadas por IA sin datos propios.

Paso 11 — Redactar la síntesis de cada pregunta

Para qué sirve. Convierte tus tablas y conteos en un texto que responde la pregunta de forma ordenada y verificable.

Qué necesitas. Las categorías, los conteos, la tabla y figura, la sensibilidad y la certeza de cada pregunta.

Cómo hacerlo:

1. **Apertura (3–5 líneas).** Responde la pregunta en forma afirmativa e indica el n, el método y la tabla y figura.
2. **Un párrafo por categoría (6–10 líneas)**, en este orden:
   - definición;
   - frecuencia;
   - hallazgo común con citas agrupadas;
   - dato cuantitativo;
   - calidad y certeza.
3. **Contrastes (4–6 líneas).** Los estudios que contradicen a la mayoría, citados por separado.
4. **Cierre (3–5 líneas).** Tendencias, vacíos y resultado de la sensibilidad.
5. Revisa la extensión total según el n de la pregunta: menos de 15 estudios, 25–35 líneas; entre 15 y 40, 35–55 líneas; más de 40, 55–80 líneas.
6. Revisa las reglas de redacción: tercera persona, verbos neutros, porcentajes con n y una cita por hallazgo.

Ejemplo. *"Los enfoques híbridos constituyeron la categoría más frecuente (35,7 %; Tabla V, Fig. 3). Estos estudios combinaron modelos de lenguaje con reglas de negocio o grafos de conocimiento para reducir errores de clasificación [71]–[85]. Diez de ellos reportaron mejoras de exactitud de entre 8 y 15 puntos porcentuales frente a modelos no híbridos [72], [75], [78]–[85]; en cambio, cuatro estudios no observaron diferencias significativas [90]–[93]."*

Producto. El texto de cada pregunta, con sus cuatro bloques.

Errores comunes. Escribir un párrafo por artículo ("El autor X hizo… El autor Y hizo…"); opinar ("esto es muy prometedor"); olvidar los contrastes.

Paso 12 — Verificar la trazabilidad

Para qué sirve. Garantiza que no haya errores de citación ni datos sin respaldo antes de entregar.

Qué necesitas. El texto de Resultados, la lista de referencias y la tabla de mapeo.

Cómo hacerlo:

1. Marca en la hoja "Corpus" cada estudio que aparezca citado en Resultados. Todos deben quedar marcados.
2. Por cada pregunta, compara los estudios citados en su texto con los de su hoja de mapeo. No debe haber estudios citados que no estén mapeados.
3. Verifica que cada [n] del texto tenga su entrada en la lista y que cada entrada esté citada.
4. Suma los n de cada tabla. Si un estudio aparece en varias categorías, aclara al pie de la tabla que las categorías no son excluyentes.
5. Toma al azar 5 cifras del texto y rastréalas hasta la hoja de extracción y la página del artículo. Cada una debe encontrarse en menos de un minuto.

Producto. La hoja "Corpus" con todos los estudios marcados y una lista de verificación sin errores.

Errores comunes. Estudios del corpus que nunca se citan; números [n] que apuntan al artículo equivocado.

Paso 13 — Publicar los datos y autoevaluarse

Para qué sirve. Permite que cualquier evaluador o revisor de la revista compruebe tu trabajo. Es una exigencia frecuente en revistas Q2.

Qué necesitas. Todos los archivos de los pasos anteriores.

Cómo hacerlo:

1. Reúne en una carpeta:
   - la matriz general;
   - las hojas por pregunta;
   - la bitácora;
   - las hojas de doble evaluación con sus Kappa;
   - la exportación de Scopus y WoS;
   - los archivos o el código de las figuras.
2. Crea una cuenta gratuita en OSF (osf.io) o Zenodo (zenodo.org) y sube la carpeta como un proyecto.
3. Genera el DOI del proyecto y cítalo en el artículo, en la sección "Disponibilidad de datos".
4. Completa el checklist por pregunta y el checklist de la sección. Corrige todo ítem sin marcar.
5. Declara en el anexo cualquier uso de herramientas de IA, indicando la sección y la tarea.

Producto. El repositorio con DOI, los checklists completos y la declaración de uso de IA.

Errores comunes. Subir solo el artículo y no los datos; marcar el checklist sin verificar realmente cada ítem.

5. Protocolo de respuesta para cada pregunta de investigación

5.1 Acopio de información por pregunta

Hoja de extracción por pregunta. Además de la matriz general, se crea en el mismo Excel una hoja por cada pregunta (PI1, PI2…). Cada fila es un estudio mapeado a esa pregunta y tiene estas columnas:

- ID e identificador [n];
- el fragmento literal del estudio que responde la pregunta, de no más de 40 palabras, con su página y sección;
- el dato cuantitativo asociado (valor, métrica y comparador);
- el código asignado y la categoría a la que pertenece;
- la dirección del efecto (mejora, sin diferencia, empeora o no aplica);
- el nivel de calidad según el QA.

Regla del acopio. Ningún dato entra a la hoja sin su ubicación exacta en el artículo (página, tabla o sección). Si el estudio no reporta el dato, se registra "No reporta"; nunca se deduce ni se completa por similitud con otro estudio.

Bitácora de codificación. Es una hoja aparte donde se registra cada código creado, su definición, la fecha, quién lo creó y en qué categoría se integró. Cuando dos códigos se fusionan, se anota el motivo. Es la evidencia de que las categorías emergieron de los datos.

Doble verificación. El segundo integrante revisa al menos el 20 % de las filas de cada hoja, y se calcula el Kappa sobre la columna "categoría". Los desacuerdos y su resolución se registran en la bitácora.

5.2 Estrategia de respuesta según el tipo de pregunta

Preguntas de identificación ("¿qué técnicas, factores, herramientas…?"). Se aplica síntesis temática: se codifica cada fragmento, se agrupan los códigos en categorías, se definen y se cuentan. El resultado es una tipología con frecuencias.

Preguntas de efecto o comparación ("¿mejora…?", "¿en qué medida…?", "¿frente a…?"). Se aplica SWiM: se agrupan los estudios por comparador y métrica, se cuenta cuántos reportan mejora, ninguna diferencia o empeoramiento, y se reporta el rango de valores de la métrica. Nunca se promedian métricas de datasets distintos.

Preguntas de mecanismo o condiciones ("¿cómo…?", "¿bajo qué condiciones…?"). Se aplica síntesis narrativa estructurada: se agrupan los estudios según la condición y se describe qué resultados aparecen en cada grupo. Se identifican patrones sin atribuir causalidad; la explicación causal va en la Discusión.

Preguntas de desafíos o limitaciones ("¿qué barreras…?"). Se aplica síntesis temática con conteo, separando las limitaciones reportadas por los autores de las observadas en el diseño del estudio, por ejemplo la falta de comparador o un dataset sintético.

Preguntas bibliométricas o de cobertura ("¿cómo se distribuye…?", "¿dónde…?", "¿cuándo…?"). Se aplica un mapeo sistemático con conteos, gráficos de burbujas y análisis de redes de coocurrencia, para mostrar concentraciones y vacíos.

5.3 Estructura y extensión de cada respuesta

Las extensiones se calculan sobre una columna IEEE a 10 puntos, que contiene unas 10–11 palabras por línea. Cada respuesta a una pregunta tiene cuatro bloques.

Bloque 1 — Apertura (3–5 líneas, unas 40–50 palabras). Repite la pregunta en forma afirmativa, indica cuántos estudios la responden (n y porcentaje del corpus), el método de síntesis aplicado y la tabla y figura correspondientes.

Modelo: "Treinta y dos estudios (38,1 %) abordaron las técnicas de IA aplicadas a la clasificación de incidentes (PI1). Mediante síntesis temática se identificaron cuatro categorías (Tabla VI, Fig. 4)."

Bloque 2 — Desarrollo por categoría (6–10 líneas por categoría, unas 70–100 palabras). Cada categoría se desarrolla en un párrafo con cinco elementos, en este orden:

1. definición de la categoría en una oración;
2. frecuencia (n y %);
3. hallazgo común, con citas agrupadas;
4. dato cuantitativo representativo (rango de la métrica o dirección del efecto);
5. proporción de estudios de calidad alta y certeza CERQual.

Si una categoría reúne más de 15 estudios, puede dividirse en dos párrafos por subcategoría, con un máximo de 14 líneas por párrafo.

Bloque 3 — Contrastes (4–6 líneas, unas 50–60 palabras). Reporta los debates, es decir, los estudios con resultados contradictorios dentro de una misma categoría, citándolos por separado y sin interpretar la causa.

Bloque 4 — Cierre (3–5 líneas, unas 40–50 palabras). Reporta las tendencias temporales, los vacíos (qué no aborda ningún estudio) y el resultado del análisis de sensibilidad.

Extensión total por pregunta, proporcional a la evidencia:

- **Menos de 15 estudios:** entre 25 y 35 líneas (250–350 palabras).
- **Entre 15 y 40 estudios:** entre 35 y 55 líneas (350–550 palabras).
- **Más de 40 estudios:** entre 55 y 80 líneas (550–800 palabras).

Superar estos rangos suele indicar que se está resumiendo artículo por artículo en lugar de sintetizar.

5.4 Reglas de redacción en cada respuesta

- Cada oración con un hallazgo lleva al menos una cita [n]. Las citas agrupadas siguen el formato IEEE: "[12], [15], [18]–[22]".
- Se usan verbos de reporte neutros (reportó, aplicó, identificó, evaluó, obtuvo) y se evitan los valorativos (demostró, confirmó, probó), salvo que el estudio lo haya hecho estadísticamente.

- No se nombra a los autores en cada oración. Solo se nombra a un autor cuando su estudio es una excepción relevante.
- Todo porcentaje va con su n y con el total de referencia: "12 de 32 estudios (37,5 %)".
- No se usan adjetivos de juicio (excelente, deficiente, prometedor) ni la primera persona.
- Los párrafos tienen como máximo 3–4 líneas por idea. Si una categoría requiere más, se divide en subcategorías.

5.5 Evidencias que se deben presentar por cada respuesta

En el cuerpo del artículo:

- al menos una tabla propia de la pregunta, con categorías, estudios [n], frecuencia y porcentaje;
- al menos una figura propia de la pregunta, construida con los datos de esa tabla;
- en las preguntas de efecto, una tabla o figura de dirección del efecto por comparador;
- una tabla de resumen de hallazgos con la certeza CERQual, que puede agrupar todas las preguntas.

En los anexos o material suplementario:

- la hoja de extracción de la pregunta, con fragmentos literales, páginas y códigos;
- la bitácora de codificación, con la fusión de códigos y la resolución de desacuerdos;
- el valor de Kappa de la doble verificación, con el porcentaje de acuerdo y el tamaño de la muestra;
- la tabla del análisis de sensibilidad (conteos con y sin los estudios de calidad baja);
- el código o archivo que genera las figuras.

En el repositorio abierto (OSF o Zenodo, con DOI citado en el artículo): la matriz completa, las hojas por pregunta, la bitácora y la exportación original de Scopus y WoS.

Criterio que aplicará el docente. Cualquier cifra o afirmación de Resultados debe poder rastrearse, en menos de un minuto, hasta una fila de la hoja de extracción y una página del artículo fuente. Si no se puede rastrear, se considera un dato sin sustento.

6. Formato IEEE de tablas y figuras

- **Tablas:** "TABLA I", en números romanos, con el título en mayúsculas encima de la tabla.
- **Figuras:** "Fig. 1." con el pie debajo, en números arábigos.
- **Numeración y referencias:** numeración correlativa y cada tabla o figura citada en el texto antes de que aparezca.
- **Ejes:** con nombre y unidad, por ejemplo "Número de estudios (n)". Etiquetas legibles a 8 puntos y resolución de 300 ppp o más.
- **Fuente:** indicar al pie los estudios de los que proviene, por ejemplo "Fuente: elaboración propia a partir de [12]–[95]".

7. Ejemplos modelo

Tabla:

TABLA V

TÉCNICAS DE IA IDENTIFICADAS PARA RESPONDER PI1 (n = 84)

Categoría	**Estudios**	**n**	**%**
Aprendizaje profundo (CNN, RNN)	[12], [15], [18]–[31]	16	19,0
Modelos de lenguaje (LLM)	[33]–[52]	20	23,8
Aprendizaje automático clásico	[53]–[70]	18	21,4
Enfoques híbridos	[71]–[100]	30	35,7

Pie de figura: *Fig. 3. Distribución de los estudios según la categoría de técnica de IA aplicada (n = 84).*

Párrafo de síntesis: *"Los enfoques híbridos constituyeron la categoría más frecuente (35,7 %; Tabla V, Fig. 3). Estos estudios combinaron modelos de lenguaje con reglas de negocio o grafos de conocimiento para reducir errores de clasificación [71]–[85]. Diez de ellos reportaron mejoras de exactitud de entre 8 y 15 puntos porcentuales frente a modelos no híbridos [72], [75], [78]–[85]; en cambio, cuatro estudios no observaron diferencias significativas [90]–[93]. Ningún estudio de esta categoría evaluó el costo computacional en entornos de producción."*

El párrafo describe el dato, sintetiza varios estudios, muestra un debate y señala un vacío sin interpretarlo.

8. Errores frecuentes que se deben evitar

Detectados en ATI2:

- corpus no citado o incompleto en la lista de referencias;
- ponencias de congreso, preprints de arXiv, tesis o revisiones dentro del corpus;
- estudios ajenos al tema, a menudo por términos ambiguos en la ecuación;
- referencias sin DOI o con indicios de fabricación;
- cifras que no coinciden entre el PRISMA, las tablas y el texto;
- instrucciones de herramientas de IA olvidadas en el documento y uso de IA no declarado.

Propios de Resultados:

- resumir artículo por artículo en lugar de sintetizar;
- interpretar o valorar ("esto demuestra que…", "es evidente que…");
- crear categorías a priori que no surgen de los datos;
- responder una pregunta solo con texto, sin tabla ni figura;
- dar porcentajes sin el n del que provienen;
- citar en una pregunta estudios que no están mapeados a ella;
- reportar Kappa sin el porcentaje de acuerdo ni el tamaño de la muestra.

9. Checklists de verificación

9.1 Checklist por pregunta de investigación

Se completa una copia para cada pregunta (PI1, PI2… y preguntas bibliométricas). Si queda algún ítem sin marcar, esa respuesta no está lista para entregar.

A. Acopio y trazabilidad

- ☐ Existe la hoja de extracción de la pregunta, con una fila por cada estudio mapeado a ella.
- ☐ Cada fila tiene un fragmento literal de 40 palabras o menos, con página, sección o tabla de origen.
- ☐ Los datos no reportados figuran como "No reporta"; ninguno se dedujo.
- ☐ La bitácora de codificación registra la creación y fusión de cada código de esta pregunta.
- ☐ El segundo integrante verificó al menos el 20 % de las filas, y se reportan κ, el porcentaje de acuerdo y el tamaño de la muestra.
- ☐ Los estudios de la hoja coinciden exactamente con los que la tabla de mapeo asigna a esta pregunta.

B. Método y estrategia

- ☐ La pregunta tiene declarado su tipo (identificación, efecto, mecanismo, desafíos o bibliométrica).
- ☐ El método de síntesis corresponde al tipo de pregunta y está justificado en la Metodología.
- ☐ Las categorías emergieron de los datos y cada una tiene su definición de una oración.
- ☐ Las categorías no se superponen, o se declara explícitamente que un estudio puede pertenecer a varias.
- ☐ En las preguntas de efecto se aplicó el conteo de votos por dirección del efecto y se reporta el rango de la métrica, sin promediar datasets distintos.

C. Estructura y redacción

- ☐ La respuesta tiene los cuatro bloques: apertura, desarrollo por categoría, contrastes y cierre.
- ☐ La apertura indica el n de estudios, su porcentaje del corpus, el método aplicado y la tabla y figura correspondientes.
- ☐ Cada párrafo de categoría contiene, en orden, definición, frecuencia, hallazgo con citas, dato cuantitativo y calidad/certeza.
- ☐ Se reportan los debates citando por separado a cada estudio.
- ☐ El cierre reporta las tendencias, los vacíos y el resultado del análisis de sensibilidad.
- ☐ La extensión está dentro del rango que corresponde a su n.
- ☐ Ningún párrafo resume un solo artículo; cada uno integra varios estudios.
- ☐ La redacción usa verbos de reporte neutros, tercera persona y ningún adjetivo de juicio.

D. Evidencias

- ☐ Hay al menos una tabla propia de la pregunta, con categorías, estudios [n], frecuencia y porcentaje.
- ☐ Hay al menos una figura propia de la pregunta, construida con los datos de esa tabla.
- ☐ La tabla y la figura están en formato IEEE, numeradas y citadas en el texto antes de aparecer.
- ☐ Todo porcentaje va con su n y su total de referencia.
- ☐ Cada oración con un hallazgo tiene al menos una cita [n].
- ☐ Todos los estudios mapeados a la pregunta están citados en su respuesta.
- ☐ Los hallazgos principales de la pregunta tienen su certeza calificada (CERQual o GRADE adaptado).
- ☐ Cualquier cifra de la respuesta puede rastrearse en menos de un minuto hasta la hoja de extracción y la página del estudio fuente.

9.2 Checklist de la sección Resultados

Se completa una vez, después de cerrar todas las preguntas.

A. Corpus y coherencia global

- ☐ El n final coincide en el PRISMA, la tabla de mapeo, la lista de referencias y la apertura de Resultados.
- ☐ El corpus alcanza el mínimo exigido (80 o 35 estudios, según la antigüedad de la tecnología).
- ☐ El corpus no contiene ponencias, preprints, tesis, literatura gris, revisiones como estudios primarios ni estudios ajenos al tema.
- ☐ Todas las referencias del corpus tienen DOI resoluble o, en su defecto, una fuente verificable.

B. Análisis descriptivo

- ☐ Hay una distribución por año que cubre toda la ventana temporal declarada, con tabla y figura.
- ☐ Se presentan las revistas, los autores y los países con mayor producción, con la regla de asignación de país declarada.
- ☐ Hay un mapa de coocurrencia de palabras clave del corpus final, con el umbral declarado.
- ☐ Se describen los diseños metodológicos predominantes y su implicancia para la solidez de la evidencia.
- ☐ Se reporta la distribución de calidad (QA) del corpus y los criterios más incumplidos.

C. Cobertura de las preguntas

- ☐ Cada pregunta de investigación tiene su respuesta explícita en Resultados, no solo en Conclusiones.
- ☐ Cada pregunta tiene su checklist 9.1 completo.

☐ Hay una tabla de resumen de hallazgos con la certeza de cada hallazgo principal.

☐ Se reporta el análisis de sensibilidad global (sin los estudios de calidad baja).

D. Integridad de citas

☐ Todos los estudios del corpus se citan al menos una vez en Resultados.

☐ No hay referencias huérfanas ni citas sin referencia.

☐ La numeración de las referencias es consecutiva y consistente en todas las secciones.

☐ Ningún estudio aparece citado en una pregunta a la que no está mapeado.

E. Formato y redacción

☐ Las tablas y figuras están numeradas de forma correlativa en toda la sección y todas se citan en el texto.

☐ Las figuras tienen ejes con nombre y unidad, son legibles a 8 puntos y tienen una resolución de 300 ppp o más.

☐ La redacción es descriptiva, formal y en tercera persona; las interpretaciones se dejaron para la Discusión.

☐ La extensión total de la sección es proporcional al tamaño del corpus.

F. Transparencia y ética

☐ Se reporta el Kappa (valor, porcentaje de acuerdo y muestra) para cada aplicación: extracción, categorías, calidad y dirección del efecto.

☐ La matriz, las hojas por pregunta, la bitácora y la exportación están depositadas en OSF o Zenodo, con DOI citado.

☐ El uso de herramientas de IA está declarado en el anexo correspondiente, con la sección y la naturaleza del uso.

☐ Ninguna figura ni tabla fue generada por IA sin respaldo en la matriz de extracción.

10. Referencias metodológicas

[1] B. Kitchenham and S. Charters, "Guidelines for performing systematic literature reviews in software engineering," Keele Univ. and Durham Univ., Tech. Rep. EBSE-2007-01, 2007.

[2] M. J. Page et al., "The PRISMA 2020 statement: An updated guideline for reporting systematic reviews," BMJ, vol. 372, p. n71, 2021, doi: 10.1136/bmj.n71.

[3] J. Thomas and A. Harden, "Methods for the thematic synthesis of qualitative research in systematic reviews," BMC Med. Res. Methodol., vol. 8, art. 45, 2008, doi: 10.1186/1471-2288-8-45.

[4] D. S. Cruzes and T. Dybå, "Research synthesis in software engineering: A tertiary study," Inf. Softw. Technol., vol. 53, no. 5, pp. 440–455, 2011, doi: 10.1016/j.infsof.2011.01.004.

[5] J. Popay et al., "Guidance on the conduct of narrative synthesis in systematic reviews," ESRC Methods Programme, Lancaster Univ., 2006.

[6] M. Campbell et al., "Synthesis without meta-analysis (SWiM) in systematic reviews: Reporting guideline," BMJ, vol. 368, p. l6890, 2020, doi: 10.1136/bmj.l6890.

[7] K. Petersen, S. Vakkalanka, and L. Kuzniarz, "Guidelines for conducting systematic mapping studies in software engineering: An update," Inf. Softw. Technol., vol. 64, pp. 1–18, 2015, doi: 10.1016/j.infsof.2015.03.007.

[8] M. Aria and C. Cuccurullo, "bibliometrix: An R-tool for comprehensive science mapping analysis," J. Informetr., vol. 11, no. 4, pp. 959–975, 2017, doi: 10.1016/j.joi.2017.08.007.

[9] N. J. van Eck and L. Waltman, "Software survey: VOSviewer, a computer program for bibliometric mapping," Scientometrics, vol. 84, no. 2, pp. 523–538, 2010, doi: 10.1007/s11192-009-0146-3.

[10] S. Lewin et al., "Applying GRADE-CERQual to qualitative evidence synthesis findings: Introduction to the series," Implement. Sci., vol. 13, suppl. 1, art. 2, 2018, doi: 10.1186/s13012-017-0688-3.

[11] J. R. Landis and G. G. Koch, "The measurement of observer agreement for categorical data," Biometrics, vol. 33, no. 1, pp. 159–174, 1977, doi: 10.2307/2529310.

[12] M. L. McHugh, "Interrater reliability: The kappa statistic," Biochem. Med., vol. 22, no. 3, pp. 276–282, 2012, doi: 10.11613/BM.2012.031.

[13] J. Cohen, "Weighted kappa: Nominal scale agreement provision for scaled disagreement or partial credit," Psychol. Bull., vol. 70, no. 4, pp. 213–220, 1968, doi: 10.1037/h0026256.

[14] J. Cohen, "A coefficient of agreement for nominal scales," Educ. Psychol. Meas., vol. 20, no. 1, pp. 37–46, 1960, doi: 10.1177/001316446002000104.

[15] B. J. Shea et al., "AMSTAR 2: A critical appraisal tool for systematic reviews that include randomised or non-randomised studies of healthcare interventions, or both," BMJ, vol. 358, p. j4008, 2017, doi: 10.1136/bmj.j4008.